

Aliarvostuksen tunnistaminen osakemarkkinoilla tilastollisen analyysin avulla

Jonni Tuki
Tilastollinen data-analyysi

Tutkimuksen tavoitteena on selvittää, mitkä taloudelliset tekijät vaikuttavat yhdysvaltalaisen pienten ja keskikokoisten yhtiöiden markkina-arvostukseen ja mitkä taas eivät. Tavoitteena on myös tutkia eri kokoluokan yhtiöiden eroja liittyen aliarvostukseen ja hinnoitteluun.

Lähdemme tutkimaan asiaa markkina-arvostuksen, tarkemmin p/e luvun kautta, joka kuvaa osakkeen hinnan ja sen tuoton suhdetta. Käytämme tutkimiseen noin 120 havainnon aineistoa, joka sisältää keskenään mahdollisimman vertailukelpoisia yhtiöitä. Lähdemme tutkimaan seuraavia kysymyksiä:

Mitkä tekijät vaikuttavat osakkeen hinnoitteluun ja arvostuksen muodostumiseen?

Vaikuttaako yhtiön koko siihen kohdistuviin odotuksiin?

Onko analyysin avulla mahdollista tunnistaa yhtiöitä, jotka ovat merkittävästi aliarvostettuja?

AINEISTOSTA

Keräämäni aineisto sisältää 121 yhdysvaltalaisosakkeen listan, joka koostuu teollisuussektorin pienistä ja keskikokoisista yrityksistä, eli yhtiöt joiden markkina-arvo on noin 1-11 miljardia. Tiedot on kerätty itse tekemäni Python-koodin avulla Yahoo finance palvelusta (23.2.2026). Aineistossa esiintyy muutamia tyhjiä ruutuja, joihin ei ole saatu kerättyä tietoa python ohjelman avulla, analyysiä tehdessä, on poistettu tyhjät rivit, jotta tulos pysyy mahdollisimman realistisena.

kerätty data sisältää tietosarakkeet:

symboli (ticker) = osakkeen lyhytnimi, on kirjainyhdistelmä jota käytetään tunnistamaan yhtiö, se on uniikki jokaisella yrityksellä.

Nimi = yhtiön virallinen nimi, usein pitkä, käytetään tätä käytännön syistä vain lopullisten tulosten tulkinnaissa.

Sektor = sektori jolla yhtiön toiminta on. Tässä aineistossa kaikki yhtiöt sektorilla teollisuus eli *Industrials*.

Toimiala = tarkempi toimiala jolla yritys toimii, vaihtelee yrityskohtaisesti.

kerätty data sisältää muuttujat:

p/e = Arvostuskerroin joka kertoo kuinka monta vuotta yhtiöllä menisi maksaa siihen sijoitettu summa takaisin nykytuotolla, laskettu p/e viimeiseltä 12 kuukaudesta.

Markkina-arvo = Kertoo yrityksen kokonaishinnan, eli teoreettisen summan sille jos kaikki osakkeet olisivat kaupan.

p/b = Osakkeen hinnan ja kirjanpidollisen arvon suhde. Kertoo paljonko sijoittaja maksaa yrityksen kirjanpidollisesta arvosta. Luku 1 on ns. nollakohta, eli tilanne jossa yhtiön hinta on täsmälleen se, mitä yhtiö omistaa velkojen jälkeen.

beta = Kertoo riskistä suhteessa muuhun pörssiin. Nollakohtana on 1, jolloin yhtiö on yhtä riskialtis kuin keskiarvo yhtiö. $\beta > 1$ riskialttiimpi, $\beta < 1$, vakaampi.

Oman pääoman tuotto = Kuinka monta senttiä yhtiö tekee voittoa jokaista sijoitettua euroa kohden.

Liikevaihdon kasvu = Kuinka monta prosenttia yhtiön myynti on kasvanut verrattuna edelliseen vuoteen.

Velkaantumisaste = Paljonko yhtiöllä on velkaa suhteessa omistajien sijoittamaan pääomaan. Kertoo yhtiön vakaudesta.

Liikevoittoprosentti = Kertoo tehokkuudesta ja siitä paljonko rahaa jää prosentteina käteen kulujen jälkeen.

Vuosituotto = Kertoo onko sijoittaja vuoden aikana tappiolla vai voitolla.

Vuotuinen volatiliteetti = Kertoo kuinka paljon hinta hyppii, mitä korkeampi luku, sitä enemmän hinta voi pomppia.

AINEISTON HAVAINNOLLISTAMINEN

Alla olevassa taulukossa on esitetty keskeisille tunnusluvuille havainnollistavia arvoja.

Table 1: TUNNUSLUKUTAULUKKO - keskeisiä tunnuslukuja


	p/e	p/b	markkina-arvo	oman pääoman tuotto	liikevaihdon kasvu
keskiarvo	28.657	3.384	4.758	0.157	0.074
minimi	3.472	0.519	1.189	0.023	-0.613
mediaani	25.683	2.835	4.013	0.136	0.052
maksimi	264.214	9.713	11.491	0.750	0.915
keskihajonta	26.675	2.035	3.051	0.102	0.173
tyhjiä	6	0	0	1	0

Tunnusluvulle P/E on tyhjiä arvoja huomattavasti enemmän kuin muille, tämä johtuu siitä, että osakkeen tulos ei voi koskaan olla negatiivinen. Laskukaava:

$$P/E = \frac{\text{osakkeen hinta (P)}}{\text{Osakekohtainen tulos (E)}}$$


, ei anna matemaattisesti järkevää tulosta jos nimittäjä on negatiivinen, tästä syystä Yahoo finance ei ilmoita niitä, jolloin niiden paikalle jää tyhjät kohdat.

Alla olevasta kuvaajasta nähdään, miten yhtiöt jakautuvat tarkemmin toimialoittain industrials sektorin sisällä.



kuvaaja 1

Alla olevassa kuvaajassa nähdään miten yhtiöt jakautuvat kokonsa perusteella. Koon määrittelyyn käytetään markkina-arvoa, jota käytetään lajittelun perusteena myös myöhemmin t-testissä. Kuvaajaan piirretty pystyviiva on yhtiöiden koon mediaani.



kuvaaja 2

LINEAARINEN REGRESSIOANALYYSI - MITKÄ MUUTTUKAT OVAT MERKITTÄVIÄ?

Tutkitaan lineaarisen regressioanalyysin avulla, millä muuttujilla on suurin vaikutus p/e-arvon muodostumiseen. Selittävänä muuttujana Y toimii siis **p/e**, koska se kertoo arvoista parhaiten yhtiön saamasta arvostuksesta. Loput muuttujat toimivat selitettävinä X muuttujina. Tutkitaan selittäviä muuttujia ja tehdään muutamia muutoksia.

Ei oteta mukaan **p/b** muuttuja, koska se muodostuu hinnan ja kirjanpidollisen arvon suhteesta, joka muodostuu kaavalla

$$P/B = \frac{\text{osakkeen hinta (P)}}{\text{osakkeen kirjanpidollinen arvo (B)}}$$

jossa osoittajasta löytyy hinta, aivan kuten p/e-arvon kaavassa. **p/b** muuttuja pitäminen aiheuttaisi multikollineaarisuutta, eli suuri korrelaatio **p/e** muuttujan kanssa, joka aiheuttaisi mallin vääristymistä ja arvostuksen liiallista selittämistä tällä muuttujalla.

Ei myöskään oteta mukaan **vuosituottoa** joka kertoo onko yhtiö tappiollinen vai voitokas kuluneen vuoden aikana. Poistetaan muuttuja siksi, että sen käyttäminen loisi tilanteen, jossa yritetään selittää hinnan perusteella muodostettavaa arvostus tunnuslukua hinnan muuttumisella. Tämä on käytännössä kehä, joka vääristää mallia.

Edellä mainittujen muutosten lisäksi logaritmoidaan muuttuja **markkina-arvo**, jotta eri kokoisten yritysten tiedot ovat keskenään vertailukelpoisia. Logaritmoinnin jälkeen ei tarkastella enää euollisia eroja vaan prosentuaalisia eroja. Logaritointi ajaa lukuja lähemmäs nollaa, joka tekee datasta vertailukelpoisempaa.

Seuraavaksi tarkastellaan lineaarisen regressiomallin summary tulostetta

Malli 1: ensimmäisen regressiomallin tulokset

RESIDUAALIT:

Min	1Q	Median	3Q	Max
-24.634	-9.879	-2.992	4.320	222.938

KERTOIMET JA KESKIVIRHEET:

MUUTTUJA	KERROIN	KESKIVIRHE	MERKITSEVYYS
vakio (intercept)	34.435	13.866	*
Markkina-arvo (log)	1.976	3.888	
Beta	3.121	6.153	
Oman pääoman tuotto	-42.695	24.656	.
Liikevaihdon kasvu	31.403	14.233	*
Velkaantumisaste	-0.036	0.035	
Liikevoittoprosentti	-53.894	21.583	*
Vuotuinen volatilitaetti	8.435	27.152	

MALLIN TUNNUSLUVUT:

Havainnot (n)	110	
Selitysaste R2	0.1675	
Korjattu R2	0.1104	
Jäännöshajonta (Res. SE)	25.16 (df = 102)	
F-tilasto	2.932 (df = 7, 102)	**

merkittävyydet: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Summaryn ensimmäinen silmiinpistävä havainto on Residuaalit kohdassa, joka kertoo jäännösvirheen oleelliset arvot. Jäännösvirheen mediaani arvo -2.992 kertoo, että malli yliennustaa p/e arvoa useille osakkeille. Mallin minimi arvo -24.634 on lähes kymmenen kertaa pienempi, kuin maksimi arvo 222.938.

Keskiarvo p/e on 28.657, nuo aiemmat tulokset tarkoittavat että aineistossa on muutamia sellaisia yhtiöitä, joilla on todella korkeat p/e arvot verrattuna keskiarvoon. Nämä vääristävät tilastollista analyysiä, ja muuttujilla yritetään selittää näitä ääripään havaintoja, vaikka tilastollisesti suurin osa yhtiöistä pyörisi samoissa arvoissa. Tätä päätelmää vahvistaa se, että 50% havainnoista kuuluu kvartaalien 1 ja 3 muodostamalle välille [-9.87, 4.32] .

Ratkaisu vinoutuneen datan käsittelyyn on p/e muuttujan logaritointi, jonka jälkeen ei tulkita enään yksiköllistä muutosta vaan prosentuaalista muutosta muuttujassa. Logaritointi tasaa ääripäitä lähemmäs nollaa, joka estää yksittäisten poikkeusten dominoinnin mallissa.

Malli 2: selitettävän muuttujan logaritmoinnin jälkeiset tulokset

RESIDUAALIT:

Min	1Q	Median	3Q	Max
-1.273	-0.285	0.027	0.288	2.017

KERTOIMET JA KESKIVIRHEET:

MUUTTUJA	KERROIN	KESKIVIRHE	MERKITSEVYYS
vakio (intercept) (log)	3.302	0.277	***
Markkina-arvo (log)	0.200	0.077	*
Beta	0.004	0.123	
Oman pääoman tuotto	-1.639	0.493	**
Liikevaihdon kasvu	1.080	0.284	***
Velkaantumisasaste	-0.001	0.000	.
Liikevoittoprosentti	-2.217	0.431	***
Vuotuinen volatilitteetti	0.418	0.543	

MALLIN TUNNUSLUVUT:

Havainnot (n)	110	
Selitysaste R2	0.437	
Korjattu R2	0.398	
Jäännöshajonta (Res. SE)	0.503 (df = 102)	
F-tilasto	11.31 (df = 7, 102)	***

merkittävyydet: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Huomataan, että residuaalien mediaani asettuu nyt lähelle nollaa, joka tarkoittaa että data ei ole suuresti painottunutta kumpaankaan suuntaan. Poistetaan vielä muutama sellainen muuttuja jotka ovat p-arvon perusteella kaukana tilastollisesta merkittävyydestä, eli $p > 0.05$. Tällaisia ovat muuttujat **beta** sekä **vuotuinen volatiteetti**. Näiden muuttujien poistaminen tarkentaa mallia, koska malli ei yritä selittää turhilla muuttujilla mitään, vaan keskittää analyysin puhtaasti tilastollisesti merkitseviin muuttujiin.

Malli 3: lopullinen lineaarinen malli tilanteesta

RESIDUAALIT:

Min	1Q	Median	3Q	Max
-1.167	-0.289	0.036	0.302	2.001

KERTOIMET JA KESKIVIRHEET:

MUUTTUJA	KERROIN	KESKIVIRHE	MERKITSEVYYS
vakio (intercept) (log)	3.503	0.143	***
Markkina-arvo (log)	0.180	0.072	*
Oman pääoman tuotto	-1.624	0.484	**
Liikevaihdon kasvu	1.093	0.280	***
Velkaantumisasaste	-0.001	0.000	.
Liikevoittoprosentti	-2.321	0.411	***

MALLIN TUNNUSLUVUT:

Havainnot (n)	110	
Selitysaste R2	0.4329	
Korjattu R2	0.4057	
Jäännöshajonta (Res. SE)	0.5004 (df = 104)	

F-tilasto	15.88 (df = 5, 104)	***
-----------	---------------------	-----

merkittävyydet: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residuaalit osio kertoo nyt mediaanin 0.036 perusteella, että malli ei enää yliarvioi tai aliarvioi tuloksia, eli data ei ole vinoutunut ylös- tai alaspäin.

Muutaman muuttujan poiston jälkeen lähes kaikki muuttujat ovat tilastollisesti merkittäviä. Merkittävimmät muuttujat p/e arvoon näyttävät olevan **liikevaihdon kasvu** sekä **liikevoittoprosentti** Myös **oman pääoman tuotolla** sekä **markkina-arvolla** näyttää olevan tilastollista vaikutusta p/e arvoon.

Hieman merkitsevyyden ylärajan ulkopuolelle jää **velkaantumisaste**. Sillä on hyvin pieni vaikutus, mutta ei tilastollisesti merkittävässä 0.05 tarkkuudessa.

Vakiotermin estimaatin arvo 3.503 on lähtöpiste kun muuttujien arvot ovat nollia. Koska muuttuja on logaritmoitu, todellinen muuttujan arvo muiden arvojen ollessa nollia on $e^{3.5032} \approx 33.2$.

Selittävän muuttujan estimaatin kerroin kertoo kuinka monta prosenttia p/e luku muuttuu kun selittävä tekijä kasvaa

Markkina-arvo: Muuttujan estimaatin mukaan suuremmalla markkina-arvolla on positiivinen vaikutus p/e lukuun. Tätäkin muuttujaa tulkitaan prosentuaalisesti.

Oman pääoman tuotto: negatiivinen tulos kertoo että korkea oman pääoman tuotto johtaa mataliin p/e-arvoihin.

Liikevaihdon kasvu: kasvulla on positiivinen vaikutus p/e arvon kasvuun.

Velkaantumisaste: velkaantuminen ajaa alaspäin p/e arvoa, mutta ei merkitsevästi, sekä hyvin maltillisella kertoimella.

Liikevoittoprosentti: kasvava liikevoittoprosentti näyttää ajavan p/e arvoa alaspäin.

Negatiiviset kertoimet **oman pääoman tuotto** ja **velkaantumisaste** muuttujilla voivat tarkoittaa sitä, että sellaiset yhtiöt jotka ovat aineiston mukaan kannattavimpia, ovat hitaita vakaita kasvajia, eikä nopeita kasvajia. Markkinat saattavat antaa korkeamman p/e-arvon tappiollisille mutta nopeasti kasvaville yhtiöille. Tätä havaintoa tukee myös julkaisu (*Davidsson, Steffens & Fitzsimmons, 2009*).

Tulosteen R^2 kertoo kuinka suuren osan p/e muutoksista malli selittää, malli selittää tällä hetkellä $0.4329 \approx 43.3\%$ vaihteluista. Tätä voidaan pitää kohtalaisen hyvä tulos taloustieteessä (*EcologicLife, 2023*). Loput muutokset selittyvät muilla tekijöillä, kuten maamanpoliittisilla tilanteilla, sijoittajien käyttäytymisellä ja heidän ennalta arvaamattomuudella sekä toimialalla.


F-statistic rivi kertoo onko malli parempi kuin pelkkä p/e luvun arvaaminen. rivin p-arvo $1.334e-11$ on hyvin lähellä nollaa ja kertoo että malli on toimiva ja antaa paremman tuloksen kuin pelkkä puhdas arvaaminen.

Vastaus kysymykseen, Millä muuttujilla on suurin vaikutus p/e-arvon muodostumiseen?: Selittävät muuttujat **liikevaihdon kasvu**, **liikevoittoprosentti**, **oman pääoman tuotto** sekä **markkina-arvo** vaikuttavat eniten p/e arvon muodostumiseen.

Tarkastellaan **liikevaihdon kasvun** vaikutusta p/e lukuun kuvaajan kautta. Kuvaajan pisteet edustavat yksittäisiä yrityksiä. Kuvassa keltainen regressiosuora osoittaa sen että liikevaihdon kasvu ajaa p/e lukua ylöspäin.

LIKEVAIHDON KASVUN VAIKUTUS P/E-LUKUUN

keltainen viiva edustaa regressiosuoraa. (kuvaaja 3)



kuvaaja 3

T-TESTI - YHTIÖN KOON VAIKUTUS ARVOSTUKSEEN

Seuraavaksi selvitetään t-testin avulla, vaikuttaako yhtiön koko sen arvostukseen kohdistuviin odotuksiin. Käytetään p/e-arvossa logaritmoituja arvoja, jotta kaikki data on keskenään vertailukelpoista.

Muodostetaan kaksi ryhmää, markkina-arvon perusteella. Käytetään jakopisteenä mediaani arvoa, jolloin saadaan saman verran yhtiöitä molemmin puolin. Mediaani oli aiemmin tunnuslukutaulukossa (TABLE 1) esitetty 4.013


Molempiin ryhmiin kuuluu nyt saman verran yhtiöitä

keskisuuri	pieni
55	55

Aloitetaan tarkastelemalla kuvaajan avulla, miten p/e arvot jakautuvat näiden kokoluokkien kesken.

P/E-LUKUJEN JAKAUMA KOKOLUOKITTAIN

Harmaat pisteet edustavat poikkeavia havaintoja



kuvaaja 4

huomataan että keskisuurilla yhtiöillä p/e-arvo asettuu kapeammalle alueelle, muutamia poikkeuksia lukuunottamatta. Pienillä yrityksillä p/e asettuu hajanaisemmalle alueelle, poikkeavia havaintoja on kuitenkin vähemmän.

Kuvaajasta huomataan että p/e-arvon keskiarvo asettuu matalammalle pienillä yhtiöillä.

Hypoteesit t-testiä varten ovat

H_0 : ryhmien välillä ei ole todellista eroa

H_1 : ryhmien välillä on ero

Eli

$H_0 : \mu_1 = \mu_2$

$H_1 : \mu_1 \neq \mu_2$

T-testin tulokset:

testisuure (t)	2.22
vapausasteet (df)	88.022
p-arvo	0.028

KESKIARVOT:

keskisuuret	3.274
pienet	3.004

Lähdetään tulkitsemaan testiä p-arvon perusteella. p-arvo $0.02899 < 0.05$ eli tulos on tilastollisesti merkitävä. Lyhyesti: Ryhmien välillä on eroa, näin ollen hylätään nollahypoteesi.

Koska p/e arvo oli testissä logaritmoitu, palautetaan p/e keskiarvot vielä yksiköllisiksi arvoiksi

KESKIARVOT:

keskisuuret: $e^{3.274} = 26.44$

pienet: $e^{3.004} = 20.18$

Nyt tiedetään että aineiston perusteella keskisuurilla yhtiöillä on huomattavasti korkeampi arvostuskerroin kuin pienillä yhtiöillä.

χ^2 -TESTI - EROT PIENTEN JA KESKISUURTEN YRITYSTEN ARVOSTUKSESSA

Tutkitaan onko mahdollista löytää sellaisia yhtiöitä jotka ovat merkittävästi aliarvostettuja p/e luvun perusteella. Aloitetaan luokittelemalla yhtiöt residuaalin perusteella "aliarvostettuihin" ja "muihin". Alla residuaalit lopullisesta lineaarisesta mallista (malli3):

RESIDUAALIT:

Min	1Q	Median	3Q	Max
-1.167	-0.289	0.036	0.302	2.001

Tutkitaan ristiintaulukoimalla kuinka monta aliarvostettua yhtiötä kuuluu kumpaankin t-testissä muodostettuun kokoluokkaan. Otetaan mukaan vain aliarvostetuista neljännes, jolloin saadaan karsittua pois sellaiset yhtiöt jotka ovat sattuman kautta päätyneet mukaan, tai ovat rajatapauksia, jolloin mukaan jää vain yhtiöt jotka ovat aidosti kertoimensa perusteella aliarvostettuja. Kokoluokissa aliarvostettuja on seuraavasti:

	aliarvostetut	muut
keskisuuri	9	46
pieni	19	36

Seuraavaksi suoritetaan χ^2 -testi

Hypoteesit ovat:

H_0 : kokoluokka ja arvostusluokka ovat keskenään riippumattomia

H_1 : kokoluokka ja arvostusluokka ovat keskenään riippuvaisia

Khin neliö- testin perusteella yhtiön koon ja arvostustason välillä on tilastollisesti merkittävä yhteys

$$(\chi^2(1) = 3.88, p = 0.045)$$

p-arvon $0.04885 < 0.05$ perusteella siis hylkäämme nollahypoteesin,. Todennäköisemmin aliarvostettuja ovat pienet yhtiöt. Havaintoaineiston ollessa kohtalaisen pieni, sanoisin 10 yhtiön eron olevan merkittävä keskisuurten ja pienten yritysten välillä.

Tämä tukee t-testissä esiin tullutta huomiota siitä, että keskisuurten ja pienten yhtiöiden välillä on merkittävää arvostuksellista eroa.

HAVAINNOT - MITKÄ YHTIÖT OVAT ALIARVOSTETTUJA

Seuraavaksi kerätään aliarvostetut yhtiöt molempien kokoluokkien ryhmistä. Rajataan siten että mukaan tulee vain sellaiset yhtiöt, joiden **p/e**, **p/b** ja **beta** on alle oman suuruusluokan keskiarvon. Käytetään siis omia keskiarvoja pienille ja omia keskiarvoja keskisuurille yhtiöille.

KESKIARVOT:

	p/e	p/b	beta
keskisuuri	29.0	3.94	1.09
pieni	28.3	2.83	0.996

Nämä yhtiöt ovat analyysin perusteella aliarvostettuja. Alla olevaan taulukkoon on haettu tietojenkeruu hetken päivän keskihinta, sekä hieman vajaa kolme kuukautta myöhemmin saatu hinta.

<https://finance.yahoo.com/> (14.5.2026)

NIMI	TICKER	RESIDU- AALI	P/E	VERROKKI P/E	HINTA 23.2	HINTA 14.5	RYHMÄ
The GEO Group. Inc.	GEO	-1.129	7.08	28.3	13.31	23.26	Pieni
CoreCivic. Inc.	CXW	-0.726	14.76	28.3	16.21	21.12	Pieni
BW LPG Limited	BWLP	-0.685	15.71	28.3	17.35	20.59	Pieni
CBIZ. Inc.	CBZ	-0.588	22.47	28.3	27.68	28.73	Pieni
Maximus. Inc.	MMS	-0.568	11.12	28.3	72.38	60.30	Pieni
ABM Industries Incorporated	ABM	-0.551	17.12	28.3	44.13	39.66	Pieni
Global Ship Lease. Inc	GSL	-0.545	4.19	28.3	39.48	41.60	Pieni
Robert Half Inc.	RHI	-0.456	18.59	28.3	23.84	24.82	Pieni
Hafnia Limited	HAFN	-0.413	11.84	28.3	7.26	8.69	Pieni
ICF International. Inc.	ICFI	-0.369	14.26	28.3	75.58	61.21	Pieni
Otter Tail Corporation	OTTR	-0.358	12.75	28.3	85.46	89.82	Pieni
Copa Holdings. S.A.	CPA	-0.735	8.66	29.0	141.72	132.85	Keskisuuri
KBR. Inc.	KBR	-0.398	8.66	29.0	40.33	30.86	Keskisuuri

Tuloksia tulkittaessa huomataan, että yhtiöistä 8/13 eli noin 61.5% on tarkastelujakson päätyttyä voitolla, verrattuna alkuperäiseen hintaan. Kuten aiemmin todettiin, hinnan muutoksiin vaikuttaa monet asiat, mutta summaryn mukaan mallini selittää noin 43% osakkeiden arvostuksen muutoksista.

Hinnan nousut eivät välttämättä kerro vielä sijoituksen kannattavuudesta. Oikeasti pitäisi tarkastella mitä muut markkinat ovat tuottaneet tänä aikana, ja tarkastella olisiko sijoitus ollut kannattava. Tämän tarkastelun tarkoituksena oli ainoastaan osoittaa, että luottamalla tähän malliin, sekä toteutettuun t-testiin ja χ^2 -testiin olisi tässä tilanteessa sijoittaja jäänyt voitolle rahojensa kanssa.

PÄÄTELMÄT

Tämän projektin alussa lähdimme tutkimaan sitä, millaiset tekijät selittävät eri yhdysvaltalaisyhtiöiden arvostusta. Tilannetta tarkasteltiin pelkästään tunnuslukujen avulla, eli jätettiin kokonaan huomiotta ihmisten käyttäytyminen ja maailman tilanteet. Arvostusta tarkasteltiin p/e luvun pohjalta. Haluttiin myös tarkastella, millaisia eroja on eri kokoluokan yhtiöiden arvostuskertoimissa, ja lopulta selvittää onko mahdollista löytää merkittävästi aliarvostettuja yhtiöitä.

Lineaarista regressioanalyysiä tehdessämme logaritmoimme selitettävän muuttujan p/e sekä muuttujan marketCap, jotta kaikki data olisi keskenään vertailukelpoista. Huomasimme regressioanalyysin perusteella, että eniten yhtiön arvostukseen vaikuttaa **liikevaihdon kasvu**, joka ajaa arvostuskerrointa ylöspäin. Sama voitiin todeta myös tilanteesta piirretystä kuvaajasta.

T-testiin siirryttäessä jaettiin yhtiöt markkina-arvon mediaanin mukaan “keskisuuriin” ja “pieniin” yhtiöihin. Testin avulla saatiin selville, että eroa näiden kahden kokoluokan väliltä löytyy, ja että pienillä yrityksillä on huomattavasti pienempi arvostuskerroin kuin keskisuurilla yrityksillä.

Lopulta tutkittiin χ^2 -testin avulla sitä, onko näiden kahden ryhmän välillä eroa siinä, paljonko kumpikin sisältää aliarvostettuja yhtiöitä. Huomattiin, että näin on, sekä että pienten yhtiöiden ryhmä sisälsi yli tuplasti aliarvostettuja yhtiöitä.

Keräämäni havainnot **liikevaihdon kasvun** vaikutuksista ovat ymmärrettäviä, sillä usein sijoittaja on valmis maksamaan osakkeesta kovemman hinnan, jos sen kasvunäkymät ovat valoisat. Negatiivinen kerroin **liikevoittoprosentille** on hieman yllättävä, mutta kertoo mahdollisesti siitä, että vakavaraiset korkean marginaalin yhtiöt hinnoitellaan maltillisemmin kuin matalan marginaalin kasvuyhtiöt. Tämä ilmiö vastaa Davidssonin ym. (2009) havaintoja siitä, että nopea kasvu ja korkea kannattavuus ovat usein poissulkevia tekijöitä toisilleen.

Regressiomallin huomattiin selittävän 43% osakkeen arvostuksen muutoksista, lisäksi F-tilaston pieni p-arvo kertoo sijoittajalle että näitä lukuja seuraamalla on merkittäväsi todennäköisempää päästä parempaan lopputulokseen, kuin puhtaasti arvaamalla mikä olisi tuottava osake. Tätä vahvistaa myös lopussa keräämäni taulukko, joka kertoo että suurin osa analyysin avulla löydettyistä aliarvostetuista osakkeista on lähes kolmen kuukauden jälkeen voitokkaita.

Tilastollinen aliarvostus ei ole takuu tuotosta, mutta analyysi osoittaa, että analyysissä havaittuja merkitseviä muuttujia seuraamalla on mahdollista saavuttaa positiivista tulosta osakemarkkinoilla.

LÄHTEET

- Aineiston keräys (23.2.2026) python yfinance kirjastoa käyttäen API:n kautta: <https://finance.yahoo.com/>
- Kahden kuukauden jälkeinen hintavertailu (14.5.2026): <https://finance.yahoo.com/>
- Davidsson, P., Steffens, P., & Fitzsimmons, J. (2009). Growing profitable or growing from profits: Putting the horse in front of the cart? *Journal of Business Venturing*, 24(4), 388–406.
- EcologicLife. (2023, 23. marraskuuta). *What R-squared Value is Acceptable in Ecology?* <https://ecologiclife.com/what-r-squared-value-is-acceptable-in-ecology.html>

LIITTEET - Python-koodi, R-koodit

- Python koodi:

```
""" Ohjelma etsii käyttäjän haluamista osakkeista käyttäjän haluamat tiedot,
käyttäen yfinance kirjastoa tiedonhakuun, sekä pandas kirjastoa tiedon
tallentamiseen. Tiedonhaun nopeuttamiseen käytetään concurrent.futures
kirjastosta saatavia workereita: 'ThreadPoolExecutor'. API-kutsujen yli-
kuormitus vältetään pitämällä 300 osakkeen välein 3 minuutin (180 sekunnin)
tauko. Osakkeet tallennetaan käyttäjän nimeämään tiedostoon.

Gather_data ja workers funktiot on tehty tekoälyn (ChatGPT-4o) avulla. Muuten
koodi on omatekoinen ja on rakennettu noin vuosi sitten omia projekteja varten,
juurikin osakepoimintaan.

Jos ei toimi niin voi johtua VPN asetuksista.
"""

# kirjastot
import yfinance as yf
import pandas as pd
import time
from concurrent.futures import ThreadPoolExecutor

def sorts_stocks():
    """ Tallentaa osakkeiden symbolit tekstitiedostosta listaksi

    :return: palauttaa listan osakkeista
    """

    save_place = []
    filename = "stocks_to_search"
    try:
        with open(filename, "r") as file:
            for line in file:
                save_place.append(line.strip().upper())
    except FileNotFoundError:
        print("File not found. Program will exit shortly.")
        quit()
    return save_place

def gather_data(symbol, criteria):
    """ Kerää datan yfinancesta

    """
```

```

try:
    print(f"Haetaan: {symbol}...")
    stock = yf.Ticker(symbol)
    info = stock.info

    data = {"Ticker": symbol}
    for limit in criteria:
        data[limit] = info.get(limit)

    # Haetaan historia
    history = stock.history(period="1y")
    if not history.empty:
        end_price = history['Close']

        # laskee osakkeen prosentuaalisen kokonaistuoton
        data['Yearly_Return'] = (end_price.iloc[-1] / end_price.iloc[0]) - 1

        # laskee hinta vaihtelun
        data['Yearly_Volatility'] = end_price.pct_change().std() * (252 ** 0.5)

    return data
except Exception as e:
    print(f"Virhe tickerillä {symbol}: {e}")
    return None

def workers(stocks, criteria):
    results = []
    num_workers = 5 # saa muuttaa mutta max 10
    chunk_size = 300 # Käsitellään 300 osaketta kerrallaan
    pause_duration = 180 # 3 minuuttia

    # Jaetaan osakelista 300 osakkeen paloihin
    for i in range(0, len(stocks), chunk_size):
        chunk = stocks[i: i + chunk_size]

        print(f"\n--- Aloitetaan erä: osakkeet {i + 1} - {min(i + chunk_size, len(stocks))} ---")

        with ThreadPoolExecutor(max_workers=num_workers) as executor:
            future_to_stock = {executor.submit(gather_data, s, criteria): s for s in chunk}

            for future in future_to_stock:
                res = future.result()
                if res:
                    results.append(res)

        # Jos listassa on vielä osakkeita jäljellä tämän erän jälkeen, pidetään tauko
        if i + chunk_size < len(stocks):
            print(f"\n300 osaketta haettu. Pidetään 3 minuutin tauko...")
            time.sleep(pause_duration)
            print("Tauko ohi, jatketaan hakuja.\n")

    return results

```

```

def saving_data(everything, file):
    """ tallentaa kerätyn datan csv tiedostoon

    """

    if not everything:
        print("Ei dataa tallennettavaksi.")
        return
    df = pd.DataFrame(everything)

    df.to_csv(file, index=False, sep=';', encoding='utf-8-sig')
    print(f>Data tallennettu onnistuneesti: {file}<
)

def main():

    # kriteerit (muokkaa kutakin hakua varten(Yearly_return, Yearly_Volatility
    # haetaan aina laskuja varten))

    # vaihda kriteerit aina tarpeen mukaan
    criteria = ['longName', 'sector', 'industry', 'marketCap', 'trailingPE',
                'priceToBook', 'beta', 'returnOnEquity', 'revenueGrowth', 'debtToEquity',
                'operatingMargins', 'dividendYield']

    # tallentaa osakkeet
    stocks = sorts_stocks()

    print(f"Löydetty {len(stocks)} symbolia tiedostosta.")
    where = input("Anna tallennettavan .csv-tiedoston nimi (esim. tulokset.csv): ")

    print("Kerätään dataa lähteistä...")
    all_data = workers(stocks, criteria)

    saving_data(all_data, where)

if __name__ == "__main__":
    main()

```

- R-koodit

```

# datan lukeminen
data <- read.table("suodatetut osakkeet.csv", header = TRUE, sep = ";")
# Valitaan sarakkeet 5-14
sarakkeet <- 5:14

# Käydään sarakkeet läpi, korvataan pilkut pisteillä ja muutetaan numeroiksi
for (i in sarakkeet) {
    data[, i] <- as.numeric(gsub(",", ".", data[, i]))
}

# poistetaan viimeinen X sarake

```

```

data <- data[, -ncol(data)]

# poistetaan tyhjät rivit laskuja varten
data1 <- na.omit(data)

# kuvaajia havainnollistavasta vaiheesta
library(ggplot2)

# piirretään kuvaaja
ggplot(data1, aes(y = industry)) +
  geom_bar(fill = "steelblue") +
  scale_x_continuous(breaks = seq(0, 20, by = 2), limits = c(0, 14)) +
  theme_minimal() +
  labs(title = "YHTIÖIDEN JAKAUTUMINEN TOIMIALOITTAIN",
       x = "Lukumäärä",
       y = "Toimiala")
##
library(ggplot2)

# tallennetaan mediaani
mediaani <- 4.013

# piirretään kuvaaja
ggplot(data1, aes(x = marketcap)) +
  geom_histogram(aes(y = after_stat(density)), bins = 15, fill = 'steelblue',
                 color = 'white', alpha = 0.7) +
  geom_density(color = 'darkblue', linewidth = 1) +
  geom_vline(xintercept = mediaani, color = "red", linetype = 'dashed',
             linewidth = 1) +
  theme_minimal() +
  labs(title = "YHTIÖIDEN KOKOJAKAUMA (MARKETCAP)",
       x = "marketcap", y = "tiheys")

# Lineaarinen regressioanalyysi
# muodostetaan lineaarinen malli
lmalli1 <- lm(trailingPE ~ log(marketcap)+beta+returnOnEquity+revenueGrowth+
              debtToEquity+operatingMargins+Yearly_Volatility, data = data1)
s1 <- summary(lmalli1)
##
# muodostetaan uusi lineaarinen malli
lmalli2 <- lm(log(trailingPE) ~ log(marketcap)+beta+returnOnEquity+
              revenueGrowth+debtToEquity+operatingMargins+
              Yearly_Volatility, data = data1)
s2 <- summary(lmalli2)
##
# lopullinen lineaarinen malli
lmalli3 <- lm(log(trailingPE) ~ log(marketcap)+returnOnEquity+revenueGrowth+
              debtToEquity+operatingMargins, data = data1)
s3 <- summary(lmalli3)

```

```
##
# kuvaaja
library(ggplot2)
# tallennetaan ryhmä sarake data frameen
data1$ryhma <- ifelse(data1$marketcap > mediaani, "keskisuuri", "pieni")

# piirretään kuvaaja
ggplot(data1, aes(x = revenueGrowth, y = log(trailingPE), color = ryhma)) +
  geom_point(size = 2.5, alpha = 0.8) + # Piirtää yritykset pisteinä
  # Piirtää regressiosuoran
  geom_smooth(method = "lm", se = FALSE, color = "yellow", linewidth = 1) +
  scale_color_manual(values = c("pieni" = "steelblue", "keskisuuri" = "red")) +
  theme_minimal() +
  labs(title = "LIIKEVAIHDON KASVUN VAIKUTUS P/E-LUKUUN",
       subtitle = "keltainen viiva edustaa regressiosuoraa. (kuvaaja 3)",
       x = "Liikevaihdon kasvu (revenueGrowth)",
       y = "log(trailingPE)",
       color = "Kokoluokka")

# t-testi
tdata <- data1
tdata$logPE <- log(tdata$trailingPE)
mediaani <- 4.013

# luodaan ryhmät "keskisuuri" ja "pieni"
tdata$ryhma <- ifelse(tdata$marketcap > mediaani, "keskisuuri", "pieni")
t1 <- table(tdata$ryhma)
##
# kuvaaja
library(ggplot2)

# piirretään kuvaaja
ggplot(tdata, aes(x = ryhma, y = log(trailingPE), fill = ryhma)) +
  geom_boxplot(alpha = 0.7, outlier.color = "darkgray", outlier.size = 2) +
  scale_fill_manual(values = c("pieni" = "steelblue", "keskisuuri" = "red")) +
  theme_minimal() +
  labs(title = "P/E-LUKUJEN JAKAUMA KOKOLUOKITTAIN",
       subtitle = "Harmaat pisteet edustavat poikkeavia havaintoja",
       x = "Kokoluokka",
       y = "log(trailingPE)") +
  theme(legend.position = "none")
##
# t-testi
testi <- t.test(logPE ~ ryhma, data = tdata)

# khi2 testi
# tallennetaan residuaalit
res = resid(lmalli3)
```

```

# raja-arvo vain yksi kvartaali
ra <- quantile(res, 0.25)

# luokittelumuuttuja
kdata <- tdata
# taulukko
kdata$arvostus_luokka <- ifelse(res <= ra, "aliarvostettu", "muu")
taulukko <- table(kdata$ryhma, kdata$arvostus_luokka)

# chi testi
khitesti <- chisq.test(taulukko)

# havainnot
# luodaan uusi data frame seuranta listaksi
lista <- data.frame(
  longName = kdata$longName,
  symbol = kdata$Ticker,
  trailingPE = kdata$trailingPE,
  residuaali = resid(lmalli3),
  priceToBook = kdata$priceToBook,
  beta = kdata$beta,
  debtToEquity = kdata$debtToEquity,
  ryhma = kdata$ryhma,
  arvostus_luokka = kdata$arvostus_luokka
)

# valitaan vain ne joiden luokka on aliarvostettu
aliarvostettu <- subset(lista, arvostus_luokka == "aliarvostettu")
aliarvostettu <- aliarvostettu[order(aliarvostettu$residuaali), ]

library(dplyr)

# Lasketaan keskiarvot alkuperäisestä kdata-tilukosta ryhmittäin
ryhma_stats <- kdata %>%
  group_by(ryhma) %>%
  summarise(
    ka_pe = mean(trailingPE, na.rm = TRUE),
    ka_pb = mean(priceToBook, na.rm = TRUE),
    ka_beta = mean(beta, na.rm = TRUE)
  )

# etsitään ne jotka täsmäivät haluttuihin arvoihin
aliarvostettu_pieni <- subset(aliarvostettu,
  ryhma == "pieni" &
  trailingPE <= 28.3 &
  priceToBook <= 2.83 &
  beta <= 0.996)

# etsitään ne jotka täsmäivät haluttuihin arvoihin

```

```
aliarvostettu_keskisuuri <- subset(aliarvostettu,  
  ryhma == "keskisuuri" &  
  trailingPE <= 29.0 &  
  priceToBook <= 3.94 &  
  beta <= 1.09)
```